

CH13 RAG 檢索增強生成 解答

1	2	3	4	5	6	7	8	9	10
A	A	D	B	A	C	B	B	B	A

11	12	13	14	15	16	17	18	19	20
D	D	C	A	D	C	B	C	D	C

計分：答對 16 題以上表示這章已經穩；12~15 題請重讀答錯題目的詳解與講義對應小節；11 題以下建議整章重讀後隔一段時間再做一次。

詳解

1. RAG 最主要解決 LLM 的哪兩個問題？

答案 A 不知道公司內部與最新的資料，以及缺乏依據時容易編造

為什麼：LLM 的知識停在訓練截止日，也不知道公司內部文件；缺資料時仍會流暢地編出答案（幻覺）。RAG 在回答前先檢索公司文件，把相關段落放進 prompt，要求模型依據這些內容回答，並附上出處。

其他選項錯在哪：

- (B) 參數太少，以及 GPU 不夠：RAG 不改變模型大小，也不解決硬體問題。
- (C) 推理速度太慢，以及模型太大：RAG 多了檢索步驟，通常會稍微變慢，不是在解決速度問題。
- (D) 無法處理英文，以及無法輸出 JSON：LLM 本來就能處理英文；輸出 JSON 靠結構化輸出，不是 RAG。

2. 下列哪一個屬於「離線建立知識庫」，而不是「線上回答問題」的步驟？

答案 A 把文件切塊、產生 embedding 並存入向量資料庫

為什麼：RAG 分兩段。離線：文件解析 → 清洗 → 切塊 → embedding → 存入向量資料庫，事先做好。線上：問題向量化 → 相似度搜尋 → (rerank) → 組 prompt → 生成。分清楚兩段，除錯時才知道問題出在哪。

其他選項錯在哪：

- (B) 把段落組進 prompt 生成回答：這是線上生成步驟。
- (C) 把使用者的問題轉成向量：這是使用者提問時才做的線上步驟。
- (D) 取回相似度最高的 Top-K 段落：這是線上檢索步驟。

3. 文件解析後出現大量「第 3 頁 / 共 120 頁」「本文件僅供內部使用」這類重複文字，應該在哪一步處理？

答案 D 清洗：移除頁首頁尾與重複文字，再進行切塊

為什麼：職缺寫「處理文件解析、清洗與資料匯入流程」，清洗就是在切塊前把沒有意義的文字去掉：頁首頁尾、頁碼、重複聲明、亂碼、多餘空白。雜訊留在 chunk 裡，會稀釋語意，讓不相關的段落因為共同的頁首文字而被誤判相似。

其他選項錯在哪：

- (A) 生成：在 prompt 要求模型忽略：太晚了，雜訊已經影響 embedding 與檢索結果。
- (B) 不需要處理：重複文字會讓很多 chunk 看起來很像，干擾相似度排序。
- (C) 檢索：把 Top-K 調大：取更多段落只會帶進更多雜訊。

4. 關於 chunk overlap，下列敘述何者正確？

答案 B 讓相鄰段落共用一部分文字，避免關鍵內容剛好被切斷

為什麼：例如一條規定的前半在第 1 塊、後半在第 2 塊，檢索到任一塊都不完整。overlap 讓相鄰兩塊重複一小段文字，降低被切斷的機率。常見起點是 chunk 大小的 10~20%，再用測試集調整。

其他選項錯在哪：

- (A) 設定 overlap 會讓向量維度變小：向量維度由 embedding 模型決定，與 overlap 無關。
- (C) 設定 overlap 之後就不需要 embedding：overlap 只是切塊方式，每個 chunk 仍要產生 embedding。
- (D) overlap 越大越好，建議設成跟 chunk 一樣大：等於 chunk 大小時切塊無法前進，還會產生大量重複。

5. 為什麼問題和文件必須使用同一個 embedding 模型？

答案 A 不同模型的向量空間不同，跨模型比較相似度沒有意義

為什麼：每個 embedding 模型都有自己的「座標系統」，同一句話在不同模型得到的向量完全不同，維度也可能不同。拿 A 模型的問題向量去比 B 模型的文件向量，就像拿台北的經緯度去對另一張地圖的格子編號。所以更換 embedding 模型時，全部文件都要重新產生向量。

其他選項錯在哪：

- (B) 為了節省 API 費用：費用不是主因，用錯模型連檢索結果都是錯的。
- (C) 因為向量資料庫只能存一個模型名稱：與資料庫欄位無關。
- (D) 因為法規規定：沒有這種法規，這是技術上的限制。

6. 把 Top-K 從 3 調到 20，最可能的影響是？

答案 C 比較不會漏掉正確段落，但 prompt 變長、成本增加，也可能混入不相關內容

為什麼：Top-K 是最常調整的檢索參數，職缺也寫「調整檢索參數，優化檢索品質」。K 太小容易漏掉正確段落；K 太大會帶進不相關內容、增加成本，模型也可能被干擾或忽略中間的段落。實務上會先取較多候選，再用 rerank 挑出最相關的幾段。

其他選項錯在哪：

- (A) 一定更準，而且更便宜：段落變多，token 與成本一定增加，也不保證更準。
- (B) 回答速度一定變快：prompt 變長，生成通常會變慢。
- (D) 完全沒有影響：Top-K 直接決定放進 prompt 的內容量。

7. 設定「相似度低於門檻的段落不放進 prompt」，主要目的是？

答案 B 避免把不相關內容當成依據，搭配「找不到就說不知道」降低幻覺

為什麼：向量檢索一定會回傳「最相近」的段落，就算資料庫裡根本沒有答案。如果把這些其實不相關的段落放進 prompt，模型可能硬湊出答案。設定相似度門檻，再搭配 prompt 規則「沒有足夠依據就回答找不到」，能明顯降低幻覺。

其他選項錯在哪：

- (A) 讓回答變長：目的不是改變回答長度。
- (C) 加快 embedding 速度：與 embedding 速度無關。
- (D) 讓向量資料庫容量變小：門檻只影響這次放進 prompt 的內容，不會刪除資料庫資料。

8. BM25 與向量檢索做混合搜尋，最能補強下列哪一類查詢？

答案 B 含統編、發票號碼、法條編號等精確字串的查詢

為什麼：向量檢索擅長「意思相近」，但對精確字串不敏感，發票號碼 AB12345678 和 AB12345679 的向量可能幾乎一樣。BM25 依關鍵字比對，擅長精確代碼。關網的資料充滿統編、發票號碼、字軌、法條編號，所以混合搜尋特別實用。

其他選項錯在哪：

- (A) 需要創意的文案生成：文案生成不是檢索問題。
- (C) 圖片檢索：BM25 是文字關鍵字演算法，不處理圖片。
- (D) 意思相近但用詞不同的口語問題：這正是向量檢索本來的強項，不需要 BM25 補強。

9. Rerank (重新排序) 通常放在流程的哪個位置？

答案 B 初步檢索取得候選段落之後、組 prompt 之前

為什麼：兩階段檢索：第一階段用向量或混合檢索快速從大量文件取出例如 30~50 個候選；第二階段用較準但較慢的 Cross-Encoder 重新排序，只留前幾名放進 prompt。這樣兼顧速度與準確度。

其他選項錯在哪：

- (A) 模型生成回答之後：回答已經生成，排序已經沒有用。
- (C) 使用者登入之前：與登入流程無關。
- (D) 文件切塊之前：切塊時還沒有使用者問題，無從排序。

10. 用 metadata 過濾 (例如文件類型、生效日期、客戶統編)，最主要的用途是？

答案 A 只檢索符合條件與權限的文件，避免取用舊版或他人的資料

為什麼：Metadata 是和每個 chunk 一起存的附加欄位，例如來源檔名、頁碼、生效日期、適用客戶統編。檢索時加上條件，例如「只找生效中的法規」「只找這個統編的資料」，能避免回答舊規定，也能做權限隔離。

其他選項錯在哪：

- (B) 壓縮文件大小：與檔案大小無關。
- (C) 取代向量相似度計算：metadata 是在相似度搜尋時加上條件，不是取代。
- (D) 讓 embedding 更準確：metadata 不改變向量本身。

關網工作情境題詳解

11. 財政部更新了「折讓單開立規定」，知識庫也匯入了新版，但 AI 仍然常回答舊規定。最可能的原因是？

答案 D 舊版文件沒有下架，或檢索時沒有依生效日期過濾

為什麼：新舊兩版內容很像，向量相似度也很接近，只加入新版、不處理舊版，檢索就可能取到舊版。修正方式：匯入新版時下架或標記舊版、在 metadata 存生效日期並檢索時過濾，回答時附上版本或日期讓使用者確認。

其他選項錯在哪：

- (A) temperature 太低：temperature 影響隨機性，不會讓模型固定選到舊文件。
- (B) embedding 維度太小：新舊版本內容相近，維度大小不會決定選哪一版。
- (C) 模型參數太少：模型大小與檢索到哪一版文件無關。

12. 要把電子發票相關法規做成知識庫，較合理的切塊方式是？

答案 D 依條文、條號與段落結構切塊，並保存條號、生效日期等 metadata

為什麼：法規本身就有清楚的結構（條、項、款），依結構切塊，每塊剛好是一個完整的規定。再把條號、法規名稱、生效日期存成 metadata，回答時就能附上「依據某法第幾條」，使用者也能自行查證。

其他選項錯在哪：

- (A) 隨機切塊：破壞文件結構，無法控制品質。
- (B) 整份法規當成一個 chunk：一個 chunk 包含所有主題，語意被稀釋，也塞不進 prompt。
- (C) 每 50 個字硬切一塊：一條規定會被切成好幾段，檢索到的內容不完整。

13. 客服 RAG 上線後，客戶甲竟然問得到客戶乙的發票明細。最根本的修正是？

答案 C 檢索時依登入者的權限（例如統編）過濾文件，權限由後端判斷

為什麼：權限控管要在「檢索」這一層做，而且由後端依登入身分強制套用：檢索時只允許取出屬於這個統編的文件，別人的資料根本不會進入 prompt。這是資料外洩等級的問題，關網處理客戶稅務資料，這一點是底線。

其他選項錯在哪：

- (A) 換一個更大的模型：模型大小與資料權限無關。
- (B) 把 Top-K 調小：只是降低機率，仍可能取到他人資料。
- (D) 在 prompt 加上「請不要洩漏他人資料」：資料已經被取出放進 prompt，只靠文字提醒擋不住，也防不了注入攻擊。

14. 你調整了 chunk 大小，想知道「檢索品質有沒有變好」，最直接的指標是？

答案 A 用固定測試題計算 HitRate@k 與 MRR

為什麼：準備一批「問題 + 正確段落」的測試題。HitRate@k：正確段落有沒有出現在前 k 名；MRR：第一個正確段落排第幾名，取倒數平均。調整前後各跑一次比較數字，才能確定改動有效。

其他選項錯在哪：

- (B) 看回答字數有沒有變多：字數與檢索是否正確無關。
- (C) 看伺服器 CPU 使用率：那是效能指標，不是檢索品質。
- (D) 問同事感覺如何：主觀感覺無法穩定比較。

15. 掃描成圖片的紙本憑證 PDF 匯入後，完全檢索不到任何內容。應該優先處理？

答案 D 在解析階段加入 OCR，把影像轉成文字

為什麼：掃描檔 PDF 裡只有圖片、沒有文字層，一般解析工具抽不出文字，後面的切塊、embedding 都是空的。要先用 OCR（光學字元辨識）或多模態模型把影像轉成文字。關網的 VAT 雲端會計憑證辨識系統處理的正是這類紙本憑證。

其他選項錯在哪：

- (A) 換一個更大的 LLM：問題在前面的解析階段，生成模型再強也沒資料可用。
- (B) 把 Top-K 調到 100：資料庫裡根本沒有文字內容，取再多也是空的。
- (C) 提高 temperature：與內容能否被檢索無關。

16. 使用者問「特休可以分成半天請嗎」。Top-5 裡已經有正確段落，模型卻回答「文件未提及」。較可能需要調整？

答案 C Prompt 規則與 context 組裝，例如段落排序、長度、明確要求依據段落回答

為什麼：先判斷是「檢索錯」還是「生成錯」：正確段落已經在 Top-5 裡，代表檢索成功，問題在生成階段。可能原因：正確段落排在中間被忽略、context 太長、prompt 沒有明確要求依據段落回答、段落格式混亂。調整方式：rerank 讓正確段落排前面、減少段落數、改善 prompt。

其他選項錯在哪：

- (A) 切塊大小：正確段落已在結果中，切塊不是主要問題。
- (B) 文件解析：正確段落已經被檢索到，代表解析沒問題。
- (D) embedding 模型：已經找到正確段落，embedding 表現沒問題。

17. 公司每天新增上千份客服紀錄要放進知識庫。較好的匯入設計是？

答案 B 背景排程做增量匯入，只處理新增與變更的資料，並記錄處理狀態

為什麼：資料匯入是職缺明寫的工作內容。好的設計：用排程在背景處理；只處理新增或修改的資料（增量）；記錄每份文件的處理狀態（成功、失敗、重試次數），失敗可以單獨重跑；刪除的資料也要同步從向量資料庫移除。

其他選項錯在哪：

- (A) 請人工逐筆複製貼上：每天上千份無法人工處理。
- (C) 每次都把全部資料刪掉重建：資料量越來越大，全部重建很慢又浪費成本。
- (D) 使用者提問時才即時處理全部資料：使用者要等非常久，而且每次提問都重算。

18. 客戶用口語問「那張退貨的發票要怎麼處理？」，文件用的是「銷貨退回、進貨退出或折讓」。較能改善檢索的做法是？

答案 C 檢索前做查詢改寫 (Query Rewrite)，補上正式用語，再搭配語意檢索

為什麼：客戶常用口語、代稱 (「那張」「退貨」)，文件用正式法規用語。查詢改寫是先讓模型把問題補全並轉成正式說法，例如「銷貨退回或折讓的電子發票處理方式」，再拿去檢索。多輪對話中也能把「那張」補成具體的發票資訊。

其他選項錯在哪：

- (A) 降低 temperature：temperature 影響生成，不影響檢索。
- (B) 把 chunk 設成整份文件：語意被稀釋，檢索更不準。
- (D) 只使用 BM25 關鍵字檢索：口語和正式用語字面不同，只靠關鍵字更找不到。

19. 主管問：「規章每個月都在改，為什麼不每個月微調一次模型就好？」較好的回答是？

答案 D RAG 更新文件就能生效，還能附上出處；微調成本高、更新慢，也無法指出答案來源

為什麼：判斷口訣：「知識會變用 RAG，行為要固定用微調。」規章屬於經常變動的知識：RAG 更新文件就生效，還能附上條文出處讓人查證；微調把知識混進模型權重，要重新訓練、無法指出來源，也可能記錯。微調比較適合固定回答格式、語氣、專業術語用法。

其他選項錯在哪：

- (A) RAG 無法處理中文：RAG 可以處理中文，選中文表現好的 embedding 模型即可。
- (B) 兩者效果完全一樣：兩者解決的問題不同。
- (C) 微調比 RAG 便宜很多：每月微調要準備資料、訓練、驗證，成本通常更高。

20. RAG 回答錯誤時，你會先做哪一件事？

答案 C 檢查檢索回來的段落是否包含正確資料，分辨是檢索錯還是生成錯

為什麼：RAG 除錯的第一步永遠是「定位」。檢索結果沒有正確段落 → 查解析、清洗、切塊、embedding 模型、Top-K、metadata 過濾、是否需要混合搜尋。有正確段落卻答錯 → 查 prompt 規則、context 組裝、段落排序、temperature。最後才考慮換模型。

其他選項錯在哪：

- (A) 把 temperature 調到最高：只會讓回答更隨機。
- (B) 刪掉整個知識庫重建：沒找到原因就重建，問題可能依然存在。
- (D) 立刻換更貴的模型：如果是檢索沒找到資料，換模型也答不對，只是浪費成本。