

CH13 RAG 檢索增強生成

依關網資訊 AI 應用工程師的職缺內容與真實筆試範圍出題。先作答，再打開同資料夾的解答檔對答案。

一、觀念題 (1 ~ 10)

1. RAG 最主要解決 LLM 的哪兩個問題？

(A) 不知道公司內部與最新的資料，以及缺乏依據時容易編造 (B) 參數太少，以及 GPU 不夠 (C) 推理速度太慢，以及模型太大 (D) 無法處理英文，以及無法輸出 JSON

2. 下列哪一個屬於「離線建立知識庫」，而不是「線上回答問題」的步驟？

(A) 把文件切塊、產生 embedding 並存入向量資料庫 (B) 把段落組進 prompt 生成回答 (C) 把使用者的問題轉成向量 (D) 取回相似度最高的 Top-K 段落

3. 文件解析後出現大量「第 3 頁 / 共 120 頁」「本文件僅供內部使用」這類重複文字，應該在哪一步處理？

(A) 生成：在 prompt 要求模型忽略 (B) 不需要處理 (C) 檢索：把 Top-K 調大 (D) 清洗：移除頁首頁尾與重複文字，再進行切塊

4. 關於 chunk overlap，下列敘述何者正確？

(A) 設定 overlap 會讓向量維度變小 (B) 讓相鄰段落共用一部分文字，避免關鍵內容剛好被切斷 (C) 設定 overlap 之後就不需要 embedding (D) overlap 越大越好，建議設成跟 chunk 一樣大

5. 為什麼問題和文件必須使用同一個 embedding 模型？

(A) 不同模型的向量空間不同，跨模型比較相似度沒有意義 (B) 為了節省 API 費用 (C) 因為向量資料庫只能存一個模型名稱 (D) 因為法規規定

6. 把 Top-K 從 3 調到 20，最可能的影響是？

(A) 一定更準，而且更便宜 (B) 回答速度一定變快 (C) 比較不會漏掉正確段落，但 prompt 變長、成本增加，也可能混入不相關內容 (D) 完全沒有影響

7. 設定「相似度低於門檻的段落不放進 prompt」，主要目的是？

(A) 讓回答變長 (B) 避免把不相關內容當成依據，搭配「找不到就說不知道」降低幻覺 (C) 加快 embedding 速度 (D) 讓向量資料庫容量變小

8. BM25 與向量檢索做混合搜尋，最能補強下列哪一類查詢？

(A) 需要創意的文案生成 (B) 含統編、發票號碼、法條編號等精確字串的查詢 (C) 圖片檢索 (D) 意思相近但用詞不同的口語問題

9. Rerank (重新排序) 通常放在流程的哪個位置？

(A) 模型生成回答之後 (B) 初步檢索取得候選段落之後、組 prompt 之前 (C) 使用者登入之前 (D) 文件切塊之前

10. 用 metadata 過濾 (例如文件類型、生效日期、客戶統編)，最主要的用途是？

(A) 只檢索符合條件與權限的文件，避免取用舊版或他人的資料 (B) 壓縮文件大小 (C) 取代向量相似度計算 (D) 讓 embedding 更準確

二、關網工作情境題 (11 ~ 20)

11. 財政部更新了「折讓單開立規定」，知識庫也匯入了新版，但 AI 仍然常回答舊規定。最可能的原因是？

(A) temperature 太低 (B) embedding 維度太小 (C) 模型參數太少 (D) 舊版文件沒有下架，或檢索時沒有依生效日期過濾

12. 要把電子發票相關法規做成知識庫，較合理的切塊方式是？

(A) 隨機切塊 (B) 整份法規當成一個 chunk (C) 每 50 個字硬切一塊 (D) 依條文、條號與段落結構切塊，並保存條號、生效日期等 metadata

13. 客服 RAG 上線後，客戶甲竟然問得到客戶乙的發票明細。最根本的修正是？

(A) 換一個更大的模型 (B) 把 Top-K 調小 (C) 檢索時依登入者的權限 (例如統編) 過濾文件，權限由後端判斷 (D) 在 prompt 加上「請不要洩漏他人資料」

14. 你調整了 chunk 大小，想知道「檢索品質有沒有變好」，最直接的指標是？

(A) 用固定測試題計算 HitRate@k 與 MRR (B) 看回答字數有沒有變多 (C) 看伺服器 CPU 使用率 (D) 問同事感覺如何

15. 掃描成圖片的紙本憑證 PDF 匯入後，完全檢索不到任何內容。應該優先處理？

(A) 換一個更大的 LLM (B) 把 Top-K 調到 100 (C) 提高 temperature (D) 在解析階段加入 OCR，把影像轉成文字

16. 使用者問「特休可以分成半天請嗎」。Top-5 裡已經有正確段落，模型卻回答「文件未提及」。較可能需要調整？

(A) 切塊大小 (B) 文件解析 (C) Prompt 規則與 context 組裝，例如段落排序、長度、明確要求依據段落回答 (D) embedding 模型

17. 公司每天新增上千份客服紀錄要放進知識庫。較好的匯入設計是？

(A) 請人工逐筆複製貼上 (B) 背景排程做增量匯入，只處理新增與變更的資料，並記錄處理狀態 (C) 每次都把全部資料刪掉重建 (D) 使用者提問時才即時處理全部資料

18. 客戶用口語問「那張退貨的發票要怎麼處理？」，文件用的是「銷貨退回、進貨退出或折讓」。較能改善檢索的做法是？
- (A) 降低 temperature (B) 把 chunk 設成整份文件 (C) 檢索前做查詢改寫 (Query Rewrite)，補上正式用語，再搭配語意檢索 (D) 只使用 BM25 關鍵字檢索
19. 主管問：「規章每個月都在改，為什麼不每個月微調一次模型就好？」較好的回答是？
- (A) RAG 無法處理中文 (B) 兩者效果完全一樣 (C) 微調比 RAG 便宜很多 (D) RAG 更新文件就能生效，還能附上出處；微調成本高、更新慢，也無法指出答案來源
20. RAG 回答錯誤時，你會先做哪一件事？
- (A) 把 temperature 調到最高 (B) 刪掉整個知識庫重建 (C) 檢查檢索回來的段落是否包含正確資料，分辨是檢索錯還是生成錯 (D) 立刻換更貴的模型

作答欄

1	2	3	4	5	6	7	8	9	10
11	12	13	14	15	16	17	18	19	20